

APRENDIZADO DE MÁQUINA NA MODELAGEM DE DADOS CENSURADOS: ESTOQUE DE CARBONO DO SOLO EM PROFUNDIDADE

Felipe Brun Vergani^{1*}, Alessandro Rosa¹, Davi Marcondes Rocha¹, Taciara Zborowski Horst²

¹Universidade Tecnológica Federal do Paraná, Câmpus Santa Helena

²Universidade Tecnológica Federal do Paraná, Câmpus Dois Vizinhos

*e-mail: vergani@alunos.utfpr.edu.br

Área Temática: [06] – Ciências Exatas e da Terra

Palavras-chave: Análise de Sobrevivência; Random Survival Forest; IPC-RF; Modelo Aditivo Generalizado; Pedometria.

RESUMO

Contexto: O solo é o maior reservatório terrestre de carbono, e a quantificação precisa do estoque de carbono orgânico do solo (COS) em profundidade é essencial para inventários nacionais e mercados de carbono. Iniciativas como o MapBiomass Solo utilizam dados legados do Repositório Brasileiro de Dados de Solo (SoilData) para mapear o COS^[1].

Lacuna/Problema: Grande parte dos levantamentos amostrais é realizado apenas nas camadas superficiais de solo, gerando censura à direita (em profundidade): quando a amostragem não atinge uma profundidade de interesse, por exemplo os 30 cm utilizados pelo Painel Intergovernamental para Mudança Climática (IPCC), ou 100 cm, esses dados permanecem desconhecidos, descartando sistematicamente estas amostras, o que produz estimativas menos precisas do estoque de COS para os territórios^[2].

Objetivo: Avaliar modelos de aprendizado de máquina (AM) adaptados à censura para estimar o estoque de COS desconhecido nos limites de 30 e 100 cm de profundidade, quantificando o ganho sobre modelos que tratam os dados censurados como exatos (regressão). Essa avaliação é viabilizada pelo tratamento inovador do estoque de COS (variável cumulativa em profundidade) como a dimensão temporal em modelos de sobrevivência.

Método: A partir de 15.011 perfis de solo catalogados no SoilData (Coleção 3 do MapBiomass Solo), descritos por 54 covariáveis ambientais e espaciais fixas com imputação por k-vizinhos mais próximos, compararam-se quatro modelos sob validação cruzada espacial: Random Forest ingênuo (referência); Random Survival Forest (RSF), que lida nativamente com a censura^[3,4]; Random Forest ponderado pela probabilidade inversa de censura (IPC-RF)^[2]; e Modelo Aditivo Generalizado (GAM) de profundidade variável^[5]. O desempenho foi medido por RMSE, coeficiente de correlação de concordância (CCC) e viés nos perfis não-censurados, com a incerteza estimada por Floresta de Regressão Quantílica. A eficácia da correção foi validada impondo-se censura artificial, em diferentes proporções, sobre perfis reais amostrados em profundidade, comparando-se as predições ao estoque medido.

Resultados: O IPC-RF obteve a melhor concordância nos dois limites (CCC de 0,260 em 30 cm e 0,227 em 100 cm), com vantagem mais nítida no limite de 100 cm, onde 61% dos perfis são censurados. O RSF apresentou o pior desempenho, por comprimir o sinal preditivo ao converter a curva de sobrevivência em um valor pontual de estoque. A validação com verdade medida demonstrou que ignorar a censura subestima o estoque em até 32% (limite de 100 cm, 60% de censura), viés que o IPC-RF reduz de forma consistente.

Conclusão: A correção estatística da censura melhora a acurácia das estimativas do estoque de COS em profundidade, sendo o IPC-RF o método mais eficiente entre os avaliados. No caso do RSF, a inclusão de preditores que variam em profundidade com o estoque de COS, tem potencial de melhorar o desempenho do método. O trabalho apresenta um referencial comparativo e reproduzível de métodos para dados censurados,



CORNÉLIO
PROCÓPIO 2026
SICITE

XXXI Seminário de Iniciação Científica e Tecnológica
O que significa ser pesquisador(a) no século XXI? Ciência, formação e transformação social.
19 a 23 de outubro de 2026 - UTFPR, Cornélio Procópio, PR

e um arcabouço generalizável a outras variáveis ambientais cumulativas sujeitas à censura à direita.

AGRADECIMENTOS

Ao CNPq, pela bolsa de Iniciação em Desenvolvimento Tecnológico e Inovação (PIBITI); à Universidade Tecnológica Federal do Paraná (UTFPR), Câmpus Santa Helena; a Dra. Aline Huf dos Reis pela revisão do trabalho escrito.

REFERÊNCIAS

- [1] MAPBIOMAS. Training field soil data for annual mapping of soil organic carbon stock (0–30 cm) in Brazil, 1985–2024 (MapBiomass Soil Collection 3, Beta). **SoilData** (2025).
- [2] VAN DER WESTHUIZEN, S. et al. Mapping soil thickness by accounting for right-censored data with survival probabilities and machine learning. **European Journal of Soil Science**, v.75, n.5, e13589 (2024).
- [3] CHEN, S. et al. Probability mapping of soil thickness by random survival forest at a national scale. **Geoderma**, v.344, p.184–194 (2019).
- [4] ISHWARAN, H. et al. Random survival forests. **The Annals of Applied Statistics**, v.2, n.3, p.841–860 (2008).
- [5] DE SOUSA MENDES, W. et al. Comparison of different approaches for estimating profile soil organic carbon stocks from topsoil samples. **Geoderma**, v.460, 117404 (2025).